

UCZENIE MASZYNOWE

Dwa oblicza klasyfikacji i regresji

Ironman Performance Predictor • Wine Classifier

Dwa projekty — jeden cel: zrozumieć modele



IRONMAN PREDICTOR

Regresja

Przewidywanie czasu finiszu zawodów Ironman na podstawie profilu zawodnika.

- ~1,44 mln rekordów (dystanse 70.3 i 140.6)
- Cel: czas finiszu (liczba)
- 4 modele regresyjne + porównanie



WINE CLASSIFIER

Klasyfikacja

Rozpoznawanie winiarni pochodzenia wina po jego składzie chemicznym.

- 178 próbek, 13 cech chemicznych
- Cel: winiarnia 1 / 2 / 3 (kategoria)
- 4 modele klasyfikujące + porównanie



Ironman Predictor — od danych do wniosku

1 Dane

Dwa zbiory z Kaggle:
70.3 i 140.6

2 Czyszczenie

Konwersja czasów,
wykrycie błędów w źródle

3 Modele

LR, Random Forest,
XGBoost, MLP

4 Wniosek


Eksperyment:
wpływ dystansu

KLUCZOWY EKSPERYMENT

Z dystansem model wyjaśnia 89% zmienności. Po jego usunięciu — tylko 23%.

Imponująca skuteczność brała się niemal wyłącznie ze znajomości dystansu (70.3 vs 140.6), a nie z profilu zawodnika. Sam wiek, płeć i kraj nie wystarczają — to przykład zmiennej zakłócającej (paradoks Simpsona).

Ironman — cztery modele, niemal ten sam wynik



Co to oznacza?

- Cztery różne algorytmy dają $R^2 \approx 0,89$.
- To znak, że osiągnięto sufit informacyjny danych.
- Żaden model nie wycisnie więcej z samego profilu zawodnika.
- Ograniczeniem są dane, nie wybór modelu.



Wine Classifier — kiedy wybór modelu ma znaczenie

Część 1 — Wine

Problem **liniowo separowalny** — winiarnie tworzą wyraźnie odrębne grupy (widać to na PCA).

- Wszystkie modele trafiają 95–99%
- Najlepszy okazał się... najprostszy (Logistic Regression, 98,9%)
- Złożone modele nie mają czego poprawiać


Część 2 — Two Moons

Zbiór **nieliniowy** — dwa przeplecione półksiężyce, których prosta linia nie rozdzieli.

- Logistic Regression przegrywa (88%)
- Drzewa i sieć neuronowa: 97–98%
- Granice decyzyjne pokazują DLACZEGO — prosta linia vs zakręty

Ten sam model — odwrotny wynik

Logistic Regression: najlepszy na Wine, najgorszy na Two Moons



Wniosek

Nie ma uniwersalnie „najlepszego” modelu. Wybór musi wynikać z natury danych: na problemie prostym wygrywa model prosty, na złożonym — modele nieliniowe.

Czego uczą oba projekty

1

Krytyczne myślenie

Wysoka skuteczność nie zawsze znaczy dobry model — Ironman pokazał zmienną zakłócającą (89% → 23%).

2

Dane > model

Cztery algorytmy dały ten sam wynik — sufit wyznaczają dane, nie wybór algorytmu.

3

Dopasowanie do problemu

Wine + Two Moons: model prosty wygrywa na danych liniowych, przegrywa na nieliniowych.

4

Pełny pipeline ML

Dane → czyszczenie → modele → walidacja → wizualizacja → wnioski, w regresji i klasyfikacji.